Prueba Técnica

Científico de Datos para Soluciones con IA

Protección

Maria Isabel Rios López

CC 1000872314

+57 3147098354

marioslo@unal.edu.co

Medellín

Marzo, 2026

Índice

1. Preparación del Entorno y de los Datos **2**
1.1. Librerías necesarias 2
1.2. Lectura de la base 3

2. Exploración Inicial de la Base **3**
2.1. Primeros y últimos registros 3
2.2. Tratamiento de valores faltantes 8
2.3. Análisis descriptivos 9

3. Punto 1 — Top 5 productos por volumen e ingresos **12**
3.1. Enfoque técnico 12

4. Punto 2 — Mayor dolor de clientes **13**
4.1. Enfoque técnico 13

5. Punto 3 — Segmentación de clientes (RFM + K-Means) **15**
5.1. Enfoque técnico 15

6. Punto 4 — Arquitectura del modelo de recomendación en tiempo real **19**
6.1. Descripción del sistema 19

7. Punto 5 — Mejor ubicación para centro comercial insignia **21**

8. Punto 6 — Base de conocimientos (JSON) **23**

9. Punto 7 — System prompts para agente de IA hiper-personalizado **24**

10. Conclusiones finales **25**

11. Limitaciones y Oportunidades de Mejora **25**

12. Anexos **25**

13. Referencias **26**

Prueba técnica: Cíentifico de datos para soluciones con IA

Este documento presenta la solución a la prueba técnica propuesta por el equipo de Canales Digitales de Protección. Su propósito es explicar de manera clara el proceso seguido, incluyendo las etapas de análisis, las decisiones tomadas y las metodologías aplicadas para resolver cada uno de los desafíos planteados.
El desarrollo abarca siete componentes, desde el análisis descriptivo de ventas hasta el diseño de un agente de IA conversacional. El dataset utilizado corresponde a una base de ventas brasileñas, compuesto por nueve tablas que incluyen información de clientes, órdenes, productos, pagos, reseñas, vendedores y geolocalización, con un periodo de análisis entre septiembre de 2016 y octubre de 2018.
Para garantizar que el trabajo realizado sea accesible y comprensible para todos, se presenta este informe detallado que explica a fondo el proceso de análisis y los resultados obtenidos. Dado que no todas las personas pueden acceder al código directamente, el informe actúa como una guía comprensiva que explica los pasos y las metodologías aplicadas. Este informe ha sido elaborado para ser comprendido sin necesidad de acceder al código fuente.

El desafío fue abordado en su totalidad utilizando el lenguaje de programación Python, a través del entorno de desarrollo Visual Studio. Se emplearon diversos paquetes y bibliotecas, los cuales se detallan minuciosamente a lo largo del documento. La elaboración de esta documentación se realizó con la ayuda de LaTeX en la plataforma Overleaf.

1. Preparación del Entorno y de los Datos

Con el fin de desarrollar este proyecto de forma estructurada y reproducible, se comenzó por establecer el entorno de trabajo y preparar los datos necesarios para el análisis.

1.1. Librerías necesarias

Las librerías utilizadas en el desarrollo de este proyecto se plasma en el código siguiendo un orden que responde a las buenas prácticas en programación con Python: primero se importan las librerías estándar del lenguaje, seguidas por las bibliotecas externas para análisis de datos, visualización y modelado. Esta estructura facilita la legibilidad del código y su mantenimiento, asegurando una organización clara y coherente a lo largo del desarrollo del proyecto.

- Manipulación de datos: pandas, numpy
- Visualización: matplotlib, seaborn
- Machine learning: scikit-learn (KMeans, StandardScaler, silhouette_score)
- Utilidades: os, json

1.2. Lectura de la base

Se cargan nueve archivos CSV que conforman el modelo relacional del negocio:

Base	Registros	Descripción
customers	99.441	Identificación y ubicación geográfica de clientes
geo	1.000.163	Coordenadas geográficas por código postal
orders	99.441	Órdenes con estados y fechas del ciclo de compra
order_items	112.650	Productos incluidos en cada pedido con precios y flete
payments	103.886	Métodos y valores de pago por orden
reviews	99.224	Evaluaciones de clientes (score 1–5 y comentarios)
products	32.951	Catálogo con categorías y dimensiones físicas
translations	71	Diccionario portugués → inglés para categorías
sellers	3.095	Información de vendedores registrados

2. Exploración Inicial de la Base

Una vez cargado el conjunto de datos, se realiza a una revisión preliminar de su contenido con el fin de familiarizarse con su estructura, identificar posibles inconsistencias y entender el tipo de información disponible.

2.1. Primeros y últimos registros

Para obtener una visión general de la base, se utilizaron las funciones df.head() y df.tail() de pandas, que permiten visualizar respectivamente los primeros y últimos cinco registros de las bases. Esto facilitó la verificación de la correcta carga de los archivos y ofreció una primera aproximación al tipo de variables incluidas, sus nombres, formatos y valores representativos.

```
customers.head()
✓ 0.0s
```

	customer_id	customer_unique_id	customer_zip_code_prefix	customer_city	customer_state
0	06b8999e2fba1a1fbc88172c00ba8bc7	861eff4711a542e4b93843c6dd7febb0	14409	franca	SP
1	18955e83d337fd6b2def6b18a428ac77	290c77bc529b7ac935b93aa66c333dc3	9790	sao bernardo do campo	SP
2	4e7b3e00288586ebd08712fdd0374a03	060e732b5b29e8181a18229c7b0b2b5e	1151	sao paulo	SP
3	b2b6027bc5c5109e529d4dc6358b12c3	259dac757896d24d7702b9acbbff3f3c	8775	mogi das cruzes	SP
4	4f2d8ab171c80ec8364f7c12e35b23ad	345ecd01c38d18a9036ed96c73b8d066	13056	campinas	SP

```
customers.tail()
✓ 0.0s
```

	customer_id	customer_unique_id	customer_zip_code_prefix	customer_city	customer_state
99436	17ddf5dd5d51696bb3d7c6291687be6f	1a29b476fee25c95fbafc67c5ac95cf8	3937	sao paulo	SP
99437	e7b71a9017aa05c9a7fd292d714858e8	d52a67c98be1cf6a5c84435bd38d095d	6764	taboao da serra	SP
99438	5e28dfe12db7fb50a4b2f691faecea5e	e9f50caf99f032f0bf3c55141f019d99	60115	fortaleza	CE
99439	56b18e2166679b8a959d72dd06da27f9	73c2643a0a458b49f58cea58833b192e	92120	canoas	RS
99440	274fa6071e5e17fe303b9748641082c8	84732c5050c01db9b23e19ba39899398	6703	cotia	SP

Figura 1: Base customers

Sobre la base customers

Es un conjunto de datos que recopila información de clientes que incluye variables de identificación y ubicación geográfica. Cuenta con 99.441 registros, donde cada fila representa un cliente identificado mediante customer_id y customer_unique_id. Además, contiene variables como código postal, ciudad y estado (abreviado por siglas correspondientes al estado geografico correspondiente), que permiten realizar segmentaciones y análisis geográficos de los clientes.

```
geo.head()
✓ 0.0s
```

	geolocation_zip_code_prefix	geolocation_lat	geolocation_lng	geolocation_city	geolocation_state
0	1037	-23.545621	-46.639292	sao paulo	SP
1	1046	-23.546081	-46.644820	sao paulo	SP
2	1046	-23.546129	-46.642951	sao paulo	SP
3	1041	-23.544392	-46.639499	sao paulo	SP
4	1035	-23.541578	-46.641607	sao paulo	SP

```
geo.tail()
✓ 0.0s
```

	geolocation_zip_code_prefix	geolocation_lat	geolocation_lng	geolocation_city	geolocation_state
1000158	99950	-28.068639	-52.010705	tapejara	RS
1000159	99900	-27.877125	-52.224882	getulio vargas	RS
1000160	99950	-28.071855	-52.014716	tapejara	RS
1000161	99980	-28.388932	-51.846871	david canabarro	RS
1000162	99950	-28.070104	-52.018658	tapejara	RS

Figura 2: Base geo

Sobre la base geo

Es un conjunto de datos que recopila información georreferenciada de los clientes, incluyendo coordenadas geográficas (latitud y longitud), ciudad y estado. Cuenta con 1.000.163 registros, donde cada fila representa una ubicación específica asociada a un código postal, lo que permite realizar análisis espaciales, segmentación geográfica y estudios de distribución territorial de los clientes.

```
orders.head()
✓ 0.0s
```

	order_id	customer_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_carrier_date	order_delivered_customer_date	order_estimated_delivery_date
0	e481f51cbdc54678b7cc49136f2d6af7	9ef432eb625129730 4e76186b10a928d	delivered	2017-10-02 10:56:33	2017-10-02 11:07:15	2017-10-04 19:55:00	2017-10-10 21:25:13	2017-10-18
1	53cdb2fc8bc7dce0b6741e2150273451	b0830fb4747a6c6d20dea0b8c802d7ef	delivered	2018-07-24 20:41:37	2018-07-26 03:24:27	2018-07-26 14:31:00	2018-08-07 15:27:45	2018-08-13
2	47770eb9100c2d0c44946d9cf07ec65d	41ce2a54c0b03bf3443c3d931a367089	delivered	2018-08-08 08:38:49	2018-08-08 08:55:23	2018-08-08 13:50:00	2018-08-17 18:06:29	2018-09-04
3	949d5b44dbf5de918fe9c16f97b45f8a	f8197465ea7920adcdbec7375364d82	delivered	2017-11-18 19:28:06	2017-11-18 19:45:59	2017-11-22 13:39:59	2017-12-02 00:28:42	2017-12-15
4	ad21c59c0840e6cb83a9ceb5573f8159	8ab97904e6daea8866dbdbc4fb7aad2c	delivered	2018-02-13 21:18:39	2018-02-13 22:20:29	2018-02-14 19:46:34	2018-02-16 18:17:02	2018-02-26

```
orders.tail()
✓ 0.0s
```

	order_id	customer_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_carrier_date	order_delivered_customer_date	order_estimated_delivery_date
99436	9c5dedf39a927c1b2549525ed64a053c	39bd1228ee8140590ac3aca26f2dfe00	delivered	2017-03-09 09:54:05	2017-03-09 09:54:05	2017-03-10 11:18:03	2017-03-17 15:08:01	2017-03-28
99437	63943bddc261676b46f01ca7ac2f7bd8	1fca14ff286135 5f6e5f14306ff977a7	delivered	2018-02-06 12:58:58	2018-02-06 13:10:37	2018-02-07 23:22:42	2018-02-28 17:37:56	2018-03-02
99438	83c1379a015df1e13d02aae0204711ab	1aa71eb042121263aafbe80c1b562c9c	delivered	2017-08-27 14:46:43	2017-08-27 15:04:16	2017-08-28 20:52:26	2017-09-21 11:24:17	2017-09-27
99439	11c177c8e97725db2631073c19f07b62	b331b74b18dc79bcdf6532d51e1637c1	delivered	2018-01-08 21:28:27	2018-01-08 21:36:21	2018-01-12 15:35:03	2018-01-25 23:32:54	2018-02-15
99440	66dea50a8b16d9b4dee7af250b4be1a5	edb027a75a1449115f6b43211ae02a24	delivered	2018-03-08 20:57:30	2018-03-09 11:20:28	2018-03-09 22:11:59	2018-03-16 13:08:30	2018-04-03

Figura 3: Base orders

Sobre la base orders

La base de datos recopila información sobre las órdenes realizadas por los clientes, donde cada pedido está identificado de manera única mediante la variable order_id. Cuenta con 99.441 registros. Incluye además el estado del pedido y las fechas clave del proceso de compra y entrega, lo que permite analizar tiempos de aprobación, despacho y cumplimiento logístico frente a las fechas estimadas.

```
order_items.head()
✓ 0.0s
```

	order_id	order_item_id	product_id	seller_id	shipping_limit_date	price	freight_value
0	00010242fe8c5a6d1ba2dd792cb16214	1	4244733e06e7ecb4970a6e2683c13e61	48436dade18ac8b2bce089ec2a041202	2017-09-19 09:45:35	58.90	13.29
1	00018f77f2f0320c557190d7a144bdd3	1	e5f2d52b802189ee658865ca93d83a8f	dd7ddc04e1b6c2c614352b383efe2d36	2017-05-03 11:05:13	239.90	19.93
2	000229ec398224ef6ca0657da4fc703e	1	c777355d18b72b67abbeef9df44fd0fd	5b51032eddd242adc84c38acab88f23d	2018-01-18 14:48:30	199.00	17.87
3	00024acbcdf0a6daa1e931b038114c75	1	7634da152a4610f1595efa32f14722fc	9d7a1d34a5052409006425275ba1c2b4	2018-08-15 10:10:18	12.99	12.79
4	00042b26cf59d7ce69dfabb4e55b4fd9	1	ac6c3623068f30de03045865e4e10089	df560393f3a51e74553ab94004ba5c87	2017-02-13 13:57:51	199.90	18.14

```
order_items.tail()
✓ 0.0s
```

	order_id	order_item_id	product_id	seller_id	shipping_limit_date	price	freight_value
112645	fffc94f6ce00a00581880bf54a75a037	1	4aa6014eceb682077f9dc4bffebc05b0	b8bc237ba3788b23da09c0f1f3a3288c	2018-05-02 04:11:01	299.99	43.41
112646	fffcd46ef2263f404302a634eb57f7eb	1	32e07fd915822b0765e448c4dd74c828	f3c38ab652836d21de61fb8314b69182	2018-07-20 04:31:48	350.00	36.53
112647	fffce4705a9662cd70adb13d4a31832d	1	72a30483855e2eafc67aee5dc2560482	c3cfdc648177fdbbbb35635a37472c53	2017-10-30 17:14:25	99.90	16.95
112648	fffe18544ffabc95dfada21779c9644f	1	9c422a519119dcad7575db5af1ba540e	2b3e4a2a3ea8e01938cabda2a3e5cc79	2017-08-21 00:04:32	55.99	8.72
112649	fffe41c64501cc87c801fd61db3f6244	1	350688d9dc1e75ff97be326363655e01	f7ccf836d21b2fb1de37564105216cc1	2018-06-12 17:10:13	43.00	12.79

Figura 4: Base order_items

Sobre la base order items

La base de datos recopila información sobre los productos incluidos en cada pedido, donde cada registro está asociado a un order_id y se diferencia mediante product_id. Cuenta con 112.650 registros. Incluye además identificadores de la orden y del vendedor, junto con variables como precio, costo de envío y fecha límite de envio, lo que permite analizar el detalle de las órdenes y la dinámica de ventas y logística.

```
payments.head()
✓ 0.0s
```

	order_id	payment_sequential	payment_type	payment_installments	payment_value
0	b81ef226f3fe1789b1e8b2acac839d17	1	credit_card	8	99.33
1	a9810da82917af2d9aefd1278f1dcfa0	1	credit_card	1	24.39
2	25e8ea4e93396b6fa0d3dd708e76c1bd	1	credit_card	1	65.71
3	ba78997921bbcdc1373bb41e913ab953	1	credit_card	8	107.78
4	42fdf880ba16b47b59251dd489d4441a	1	credit_card	2	128.45

```
payments.tail()
✓ 0.0s
```

	order_id	payment_sequential	payment_type	payment_installments	payment_value
103881	0406037ad97740d563a178ecc7a2075c	1	boleto	1	363.31
103882	7b905861d7c825891d6347454ea7863f	1	credit_card	2	96.80
103883	32609bbb3dd69b3c066a6860554a77bf	1	credit_card	1	47.77
103884	b8b61059626efa996a60be9bb9320e10	1	credit_card	5	369.54
103885	28bbae6599b09d39ca406b747b6632b1	1	boleto	1	191.58

Figura 5: Base payments

Sobre la base payments

La base de datos recopila información sobre los pagos asociados a cada pedido, donde cada registro está vinculado a un order_id y se diferencia mediante payment_sequential. Cuenta con 103.886 registros. Incluye variables como el tipo de pago, número de cuotas y valor pagado, lo que permite analizar los métodos de pago y el comportamiento financiero de los clientes.

```
reviews.head()
✓ 0.0s
```

	review_id	order_id	review_score	review_comment_title	review_comment_message	review_creation_date	review_answer_timestamp	tiene_comentario
0	7bc2406110b926393aa56f80a40eba40	73fc7af87114b39712e6da79b0a377eb	4	NaN	NaN	2018-01-18 00:00:00	2018-01-18 21:46:59	False
1	80e641a11e56f04c1ad469d5645fdfde	a548910a1c6147796b98fdf73dbeba33	5	NaN	NaN	2018-03-10 00:00:00	2018-03-11 03:05:13	False
2	228ce5500dc1d8e020d8d1322874b6f0	f9e4b658b201a9f2ecdecbb34bed034b	5	NaN	NaN	2018-02-17 00:00:00	2018-02-18 14:36:24	False
3	e64fb393e7b32834bb789ff8bb30750e	658677c97b385a9be170737859d3511b	5	NaN	Recebi bem antes do prazo estipulado.	2017-04-21 00:00:00	2017-04-21 22:02:06	True
4	f7c4243c7fe1938f181bec41a392bdeb	8e6bfb81e283fa7e4f11123a3fb894f1	5	NaN	Parabéns lojas lannister adorei comprar pela I...	2018-03-01 00:00:00	2018-03-02 10:26:53	True

```
reviews.tail()
✓ 0.0s
```

	review_id	order_id	review_score	review_comment_title	review_comment_message	review_creation_date	review_answer_timestamp	tiene_comentario
99219	574ed12dd733e5fa530cfd4bbf39d7c9	2a8c23fee101d4d5662fa670396eb8da	5	NaN	NaN	2018-07-07 00:00:00	2018-07-14 17:18:30	False
99220	f389727253a9592a73be9bdfdf4ed7a	22ec9f0669f784db00fa86d035cffb602	5	NaN	NaN	2017-12-09 00:00:00	2017-12-11 20:06:42	False
99221	b3de70c89b1510c4cd3d0649fd302472	55d4004744368f5571d1f590031933e4	5	NaN	Excelente mochila, entrega super rápida. Super...	2018-03-22 00:00:00	2018-03-23 09:10:43	True
99222	1adeb9d84d72fe4e337617733eb85149	7725825d039fc1f0ceb7635e3f7d9206	4	NaN	NaN	2018-07-01 00:00:00	2018-07-02 12:59:13	False
99223	efe49f1d6f951dd88b51e6ccd4cc548f	90531360ecb1eec2a1fbb265a0db0508	1	NaN	meu produto chegou e ja tenho que devolver, po...	2017-07-03 00:00:00	2017-07-03 21:01:49	True

Figura 6: Base reviews

Sobre la base reviews

Es un conjunto de datos que recopila las evaluaciones de los pedidos, incluyendo puntuaciones y comentarios de los clientes. Cuenta con 99.224 donde cada fila representa una reseña única identificada por review_id y vinculada a una compra mediante order_id. Además, contiene variables como la calificación review_score, fechas de creación y respuesta, que permiten analizar la satisfacción del cliente y los tiempos de atención.

```
products.head()
✓ 0.0s
```

	product_id	product_category_name	product_name_lenght	product_description_lenght	product_photos_qty	product_weight_g	product_length_cm	product_height_cm	product_width_cm
0	1e9e8ef04dbcff4541ed26657ea517e5	perfumaria	40.0	287.0	1.0	225.0	16.0	10.0	14.0
1	3aa071139cb16b67ca9e5dea641aaa2f	artes	44.0	276.0	1.0	1000.0	30.0	18.0	20.0
2	96bd76ec8810374ed1b65e291975717f	esporte_lazer	46.0	250.0	1.0	154.0	18.0	9.0	15.0
3	cef67bcfe19066a932b7673e239eb23d	bebes	27.0	261.0	1.0	371.0	26.0	4.0	26.0
4	9dc1a7de274444849c219cff195d0b71	utilidades_domesticas	37.0	402.0	4.0	625.0	20.0	17.0	13.0

```
products.tail()
✓ 0.0s
```

	product_id	product_category_name	product_name_lenght	product_description_lenght	product_photos_qty	product_weight_g	product_length_cm	product_height_cm	product_width_cm
32946	a0b7d5a992ccda646f2d34e418ff5a0	moveis_decoracao	45.0	67.0	2.0	12300.0	40.0	40.0	40.0
32947	bf4538d88321d0fd44412a93c974510e6	construcao_ferramentas_iluminacao	41.0	971.0	1.0	1700.0	16.0	19.0	16.0
32948	9a7c6041fa9592d9d9d9cfe62a71f8c	cama_mesa_banho	50.0	799.0	1.0	1400.0	27.0	7.0	27.0
32949	83808703fc0706a22e264b9d75f04a2e	informatica_acessorios	60.0	156.0	2.0	700.0	31.0	13.0	20.0
32950	106392145fca363410d287a815be6de4	cama_mesa_banho	58.0	309.0	1.0	2083.0	12.0	2.0	7.0

Figura 7: Base products

Sobre la base producst

Es un conjunto de datos que recopila información técnica y logística de los artículos del catálogo. Cuenta con 32.951 donde cada fila representa un producto único identificado por product_id. Además, contiene variables como la categoría product_category_name, dimensiones físicas (peso, largo, alto y ancho), que permiten clasificar el inventario y analizar los requerimientos de envío.

```
translations.head()
```
✓ 0.0s

	product_category_name	product_category_name_english
0	beleza_saude	health_beauty
1	informatica_acessorios	computers_accessories
2	automotivo	auto
3	cama_mesa_banho	bed_bath_table
4	moveis_decoracao	furniture_decor

```
translations.tail()
```
✓ 0.0s

	product_category_name	product_category_name_english
66	flores	flowers
67	artes_e_artesanato	arts_and_craftmanship
68	fraldas_higiene	diapers_and_hygiene
69	fashion_roupa_infanto_juvenil	fashion_childrens_clothes
70	seguros_e_servicos	security_and_services

Figura 8: Base traslations

Sobre la base translations

Es un conjunto de datos que funciona como un diccionario de traducción para las categorías del catálogo. Cuenta con 71 registros donde cada fila relaciona el nombre original de la categoría en portugués product_category_name con su correspondiente traducción al inglés product_category_name_english, lo que permite estandarizar la información.

```
sellers.head()
```
✓ 0.0s

	seller_id	seller_zip_code_prefix	seller_city	seller_state
0	3442f8959a84dea7ee197c632cb2df15	13023	campinas	SP
1	d1b65fc7debc3361ea86b5f14c68d2e2	13844	mogi guacu	SP
2	ce3ad9de960102d0677a81f5d0bb7b2d	20031	rio de janeiro	RJ
3	c0f3eea2e14555b6faeea3dd58c1b1c3	4195	sao paulo	SP
4	51a04a8a6bdcb23deccc82b0b80742cf	12914	braganca paulista	SP

```
sellers.tail()
```
✓ 0.0s

	seller_id	seller_zip_code_prefix	seller_city	seller_state
3090	98dddbc4601dd4443ca174359b237166	87111	sarandi	PR
3091	f8201cab383e484733266d1906e2fdfa	88137	palhoca	SC
3092	74871d19219c7d518d0090283e03c137	4650	sao paulo	SP
3093	e603cf3fec55f8697c9059638d6c8eb5	96080	pelotas	RS
3094	9e25199f6ef7e7c347120ff175652c3b	12051	taubate	SP

Figura 9: Base sellers

Sobre la base sellers

Es un conjunto de datos que recopila información sobre los vendedores registrados en la plataforma. Cuenta con 3.095 registros donde cada fila representa un proveedor único identificado por seller_id. Además, contiene variables de ubicación geográfica como el prefijo del código postal seller_zip_code_prefix, la ciudad seller_city y el estado seller_state.

2.2. Tratamiento de valores faltantes

Se identificaron presencia de valores NA en algunas tablas (especialmente en comentarios de reseñas). Se optó por conservarlos sin imputar, dado que representan situaciones válidas del negocio: un campo vacío de comentario no es un error, sino un cliente que eligió no escribir. La estrategia adoptada fue filtrar únicamente la información necesaria en cada análisis puntual.

Resultados análisis NA y valores nulos

```
==================================================
Resumen de la base de datos: TRANSLATIONS
==================================================
                                dtype  non_null_count  na_count  null_count
product_category_name          object              71         0           0
product_category_name_english  object              71         0           0
```

```
==================================================
Resumen de la base de datos: PRODUCTS
==================================================
                            dtype  non_null_count  na_count  null_count
product_id                 object           32951         0           0
product_category_name      object           32341       610         610
product_name_lenght       float64           32341       610         610
product_description_lenght float64          32341       610         610
product_photos_qty        float64           32341       610         610
product_weight_g          float64           32949         2           2
product_length_cm         float64           32949         2           2
product_height_cm         float64           32949         2           2
product_width_cm          float64           32949         2           2
```

```
==================================================
Resumen de la base de datos: ORDERS
==================================================
                                     dtype  non_null_count  na_count
order_id                            object           99441         0
customer_id                         object           99441         0
order_status                        object           99441         0
order_purchase_timestamp  datetime64[ns]           99441         0
order_approved_at         datetime64[ns]           99281       160
order_delivered_carrier_date datetime64[ns]        97658      1783
order_delivered_customer_date datetime64[ns]       96476      2965
order_estimated_delivery_date datetime64[ns]       99441         0
```

```
==================================================
Resumen de la base de datos: ORDER_ITEMS
==================================================
                       dtype  non_null_count  na_count  null_count
order_id              object          112650         0           0
order_item_id          int64          112650         0           0
product_id            object          112650         0           0
seller_id             object          112650         0           0
shipping_limit_date   object          112650         0           0
price                float64          112650         0           0
freight_value        float64          112650         0           0
```

```
==================================================
Resumen de la base de datos: PAYMENTS
==================================================
                        dtype  non_null_count  na_count  null_count
order_id               object          103886         0           0
payment_sequential      int64          103886         0           0
payment_type           object          103886         0           0
payment_installments    int64          103886         0           0
payment_value         float64          103886         0           0
```

```
==================================================
Resumen de la base de datos: CUSTOMERS
==================================================
                         dtype  non_null_count  na_count  null_count
customer_id             object           99441         0           0
customer_unique_id      object           99441         0           0
customer_zip_code_prefix  int64          99441         0           0
customer_city           object           99441         0           0
customer_state          object           99441         0           0
```

```
==================================================
Resumen de la base de datos: GEOLOCATION
==================================================
                            dtype  non_null_count  na_count  null_count
geolocation_zip_code_prefix  int64         1000163         0           0
geolocation_lat            float64         1000163         0           0
geolocation_lng            float64         1000163         0           0
geolocation_city            object         1000163         0           0
geolocation_state           object         1000163         0           0
```

```
==================================================
Resumen de la base de datos: SELLERS
==================================================
                        dtype  non_null_count  na_count  null_count
seller_id              object            3095         0           0
seller_zip_code_prefix  int64            3095         0           0
seller_city            object            3095         0           0
seller_state           object            3095         0           0
```

```
==================================================
Resumen de la base de datos: REVIEWS
==================================================
                          dtype  non_null_count  na_count  null_count
review_id                object           99224         0           0
order_id                 object           99224         0           0
review_score              int64           99224         0           0
review_comment_title     object           11568     87656       87656
review_comment_message   object           40977     58247       58247
review_creation_date     object           99224         0           0
review_answer_timestamp  object           99224         0           0
```

2.3. Análisis descriptivos

Distribución de estados de órdenes

Métrica	Valor
Distribución de estados de órdenes	
Delivered	96,478
Shipped	1,107
Canceled	625
Unavailable	609
Invoiced	314
Processing	301
Created	5
Approved	2
Rango temporal del dataset	
Primera orden	2016-09-04
Última orden	2018-10-17
Resumen de entregas	
Órdenes entregadas	96,478 (97.0 %)

Cuadro 1: Distribución de estados de órdenes y resumen temporal del dataset

En general, se observa que la gran mayoría de las órdenes corresponden a pedidos entregados, representando el 97 % del total, lo que indica un alto nivel de cumplimiento en el proceso logístico. Los demás estados tienen diferente partipación, siendo shipped, canceled y unavailable los más relevantes dentro de este grupo.

Por otra parte, el rango temporal del dataset abarca desde septiembre de 2016 hasta octubre de 2018, lo que proporciona una ventana de análisis suficientemente amplia para identificar patrones en el comportamiento de las órdenes.

Distribución de medios de pago

Métrica	Valor
Distribución de medios de pago	
Credit card	76,795
Boleto	19,784
Voucher	5,775
Debit card	1,529
Not defined	3
Resumen de pagos	
Total registros de pago	103,886
Órdenes únicas con pago	99,440
Órdenes con múltiples métodos	2,246

Cuadro 2: Distribución de medios de pago y resumen de transacciones

En general, se observa la distribución de los diferentes medios de pago utilizados por los clientes, lo que permite identificar cuáles son los más frecuentes dentro del dataset. Asimismo, el número total

de registros de pago es superior al número de órdenes únicas, lo que indica que una misma orden puede estar asociada a uno o varios pagos. Adicionalmente, se identifica que existe un conjunto de órdenes en las que se utilizaron múltiples métodos de pago, lo que refleja cierta flexibilidad en el proceso de compra y evidencia comportamientos más complejos por parte de algunos clientes al momento de realizar sus transacciones.

Distribución de medios de review_score

Métrica	**Valor**
Distribución de puntajes	
Score 1	11,424
Score 2	3,151
Score 3	8,179
Score 4	19,142
Score 5	57,328
Estadísticas descriptivas	
Count	99,224
Mean	4.09
Std	1.35
Min	1.00
25 %	4.00
50 %	5.00
75 %	5.00
Max	5.00
Segmentación de sentimiento	
Negativo (1-2)	14,575 (14.7 %)
Neutro (3)	8,179 (8.2 %)
Positivo (4-5)	76,470 (77.1 %)
% de reseñas con comentario por puntaje	
Score 1	76.55 %
Score 2	68.07 %
Score 3	43.49 %
Score 4	31.22 %
Score 5	35.85 %

Cuadro 3: Distribución y análisis de reviews

En general, se observa una clara concentración de los puntajes en valores altos, con una media de 4.09 y una mediana de 5, lo que indica una alta satisfacción por parte de los clientes. Aproximadamente el 77.1 % de las reseñas son positivas (4–5), mientras que las negativas representan el 14.7 % y las neutrales el 8.2 %, evidenciando una percepción mayoritariamente favorable del servicio. Adicionalmente, se identifica que los clientes tienden a dejar más comentarios cuando la experiencia es negativa, alcanzando el 76.55 % en los puntajes más bajos, mientras que en calificaciones altas la proporción de comentarios es considerablemente menor. Esto sugiere que las reseñas escritas están más asociadas a experiencias que no cumplen las expectativas.

3. Punto 1 — Top 5 productos por volumen e ingresos

3.1. Enfoque técnico

Se filtran únicamente las órdenes con order_status == 'delivered'. Se realiza un JOIN entre order_items, products y product_category_name_translation para obtener las categorías en inglés. Se agrupa por categoría calculando: (a) número de unidades vendidas y (b) suma de ingresos por precio de producto.

Resultados

#	Categoría	Unidades Vendidas
1	bed_bath_table	10.953
2	health_beauty	9.465
3	sports_leisure	8.431
4	furniture_decor	8.160
5	computers_accessories	7.644

Cuadro 4: Top 5 categorías por volumen (unidades vendidas)

#	Categoría	Ganancia Total (BRL)
1	health_beauty	$1,233,131.72
2	watches_gifts	$1,166,176.98
3	bed_bath_table	$1,023,434.76
4	sports_leisure	$954,852.55
5	computers_accessories	$888,724.61

Cuadro 5: Top 5 categorías por ingresos (ganancia total en BRL)

Gráficamente

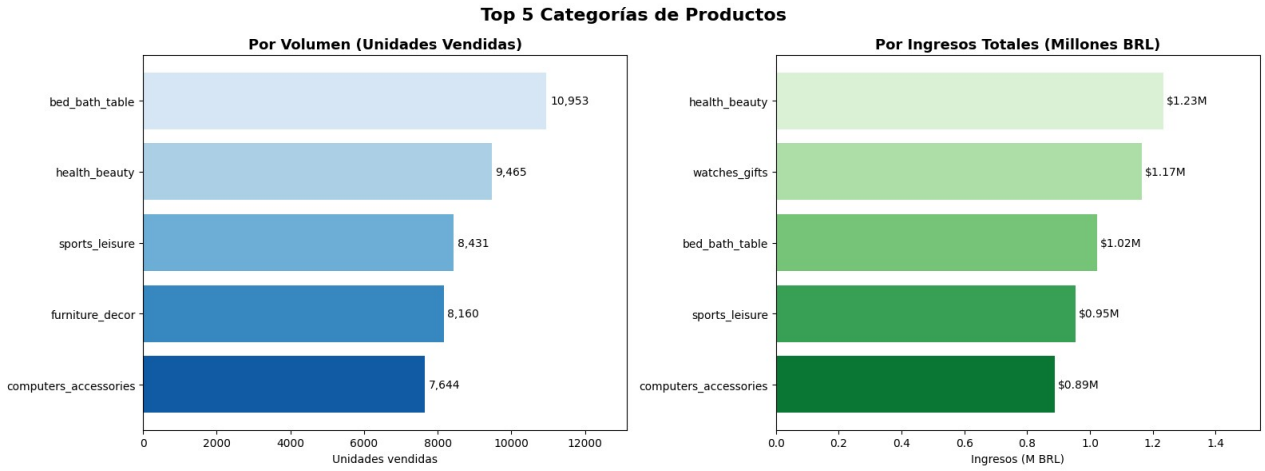

Figura 10: Punto 1

En general, se observa que las categorías con mayor volumen de ventas no necesariamente coinciden con aquellas que generan mayores ingresos. Por ejemplo, bed_bath_table lidera en unidades vendidas, pero es health_beauty la que encabeza en términos de ingresos, seguida de watches_gifts.

Esto sugiere que existen diferencias en los precios promedio entre categorías, donde algunas venden más volumen a menor precio, mientras que otras, con menor cantidad de unidades, logran mayores ingresos. En conjunto, estos resultados permiten identificar tanto categorías de alta rotación como aquellas de mayor valor económico dentro del negocio.

4. Punto 2 — Mayor dolor de clientes

4.1. Enfoque técnico

Se analizan las order_reviews con review_score igual a 1 o 2 (14.7 %). Se realiza análisis de frecuencia de palabras clave en los comentarios (escritos en portugués) para identificar temas recurrentes. Posteriormente se cruza con categorías de productos para identificar cuáles concentran más quejas. Adicionalmente, se analiza el impacto de la entrega tardía comparando el order_delivered_customer_date contra el order_estimated_delivery_date.
Resultados

Métrica	Valor
Reviews totales	99,224
Reviews negativas (1-2)	14,575
Porcentaje negativas	14.7 %

Cuadro 6: Resumen general de reviews

Tema de dolor	Menciones
No entregado / no llegó	2,398
Problemas de entrega (general)	1,974
Producto incorrecto	1,524
Demora / atraso	1,419
Producto defectuoso / calidad	1,026
Mal servicio al cliente	930

Cuadro 7: Frecuencia de temas de dolor en reviews negativas

En general, aunque las reseñas negativas representan solo el 14.7 % del total, permiten identificar que los principales puntos de dolor están asociados principalmente a la logística de entrega. Las mayores incidencias corresponden a pedidos no recibidos, problemas generales en la entrega y retrasos, lo que evidencia que la experiencia post-compra es un factor crítico.

Adicionalmente, se presentan inconvenientes como productos incorrectos y defectos de calidad, así como fallas en el servicio al cliente. En conjunto, estos resultados sugieren que las principales

oportunidades de mejora se concentran en la gestión logística y en el control de calidad, aspectos clave para fortalecer la satisfacción del cliente.

Métrica	**Valor**
Tasa de entregas tardías	8.1 %

Cuadro 8: Tasa de entregas tardías

Tipo de entrega	**Score promedio**	**Cantidad**
A tiempo	4.294	88.661
Tardía	2.566	7.700

Cuadro 9: Score promedio según tipo de entrega

#	**Categoría**	**Reviews negativas**
1	bed_bath_table	2.112
2	furniture_decor	1.621
3	computers_accessories	1.461
4	health_beauty	1.321
5	sports_leisure	1.260
6	housewares	1.086
7	watches_gifts	967
8	telephony	761

Cuadro 10: Top 8 categorías con mayor número de reviews negativas

En general, se observa que, aunque la tasa de entregas tardías es relativamente baja (8.1 %), su impacto en la satisfacción del cliente es significativo. Las órdenes entregadas a tiempo presentan un puntaje promedio alto (4.29), mientras que las tardías disminuyen considerablemente a 2.57, evidenciando una fuerte relación entre el cumplimiento en los tiempos de entrega y la percepción del servicio.

Por otra parte, las categorías con mayor número de reseñas negativas coinciden en gran medida con aquellas de alto volumen de ventas, como bed_bath_table, furniture_decor y computers_accessories. Esto sugiere que, además de la logística, el volumen de transacciones también influye en la cantidad de incidencias. En conjunto, los resultados refuerzan la importancia de optimizar los tiempos de entrega y monitorear de cerca las categorías más demandadas para mejorar la experiencia del cliente.

Gráficamente

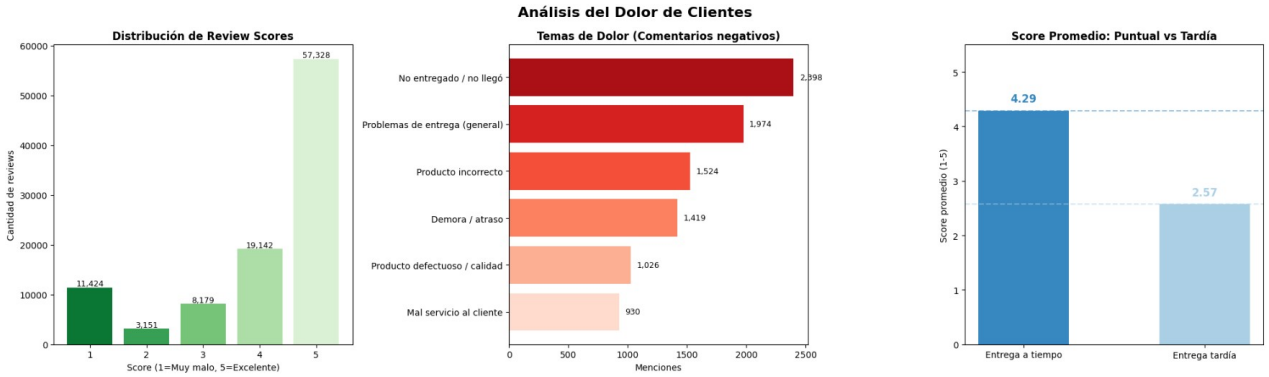

Figura 11: Punto 2

En general, se observa que, aunque la satisfacción de los clientes es alta, los principales focos de insatisfacción están asociados a la logística de entrega, especialmente en casos de pedidos no recibidos o con retrasos. En este sentido, la experiencia post-compra, particularmente el cumplimiento en los tiempos de entrega, se posiciona como el factor más determinante en la satisfacción, evidenciado en la fuerte caída del puntaje promedio cuando las órdenes se entregan tarde.

En conjunto, los resultados sugieren que el principal dolor del cliente es logístico y no de producto, por lo que las oportunidades de mejora se concentran en la optimización de la cadena logística, el cumplimiento en los tiempos de entrega y el monitoreo de las categorías de mayor demanda.

5. Punto 3 — Segmentación de clientes (RFM + K-Means)

5.1. Enfoque técnico

Se construye una matriz RFM a nivel de customer_unique_id (se usa el identificador único del cliente, no el transaccional, dado que un mismo cliente puede tener múltiples customer_id):

- Recency (R): días desde la última compra, usando como fecha de referencia el 2018-08-30 (día siguiente a la última compra registrada en el dataset).
- Frequency (F): número total de órdenes entregadas por cliente.
- Monetary (M): valor total pagado (suma de payment_value) por cliente.

Las tres variables se escalan con StandardScaler antes de aplicar K-Means. El número óptimo de clusters se determina mediante el método del codo, que evalúa la inercia interna para distintos valores de K.

Resultados RFM

Métrica	Recency	Frequency	Monetary
Información general			
Fecha de referencia			2018-08-30
Clientes únicos			93,358
Estadísticas			
Count	93358.00	93358.00	93358.00
Mean	237.94	1.03	165.20
Std	152.59	0.21	226.31
Min	1.00	1.00	0.00
25 %	114.00	1.00	63.05
50 %	219.00	1.00	107.78
75 %	346.00	1.00	182.56
Max	714.00	15.00	13664.08

Cuadro 11: Resumen completo del análisis RFM

En general, se observa que la base está compuesta por 93,358 clientes únicos, con una fecha de referencia para Recency del 2018-08-30. Los resultados evidencian que la mayoría de los clientes presenta una frecuencia de compra muy baja (mediana y percentiles en 1), lo que sugiere un comportamiento predominantemente ocasional.

Por otra parte, el gasto (Monetary) muestra una alta dispersión, con valores máximos considerablemente elevados frente a la mediana, lo que indica la existencia de un grupo reducido de clientes de alto valor. Asimismo, la variable *Recency* presenta una amplia variabilidad, reflejando tanto clientes recientes como otros con largos periodos de inactividad. En conjunto, estos patrones sugieren una base de clientes poco recurrente, con oportunidades claras para estrategias de fidelización y retención.

Selección de K

Para la selección de la **K óptima** se utiliza el método del codo:

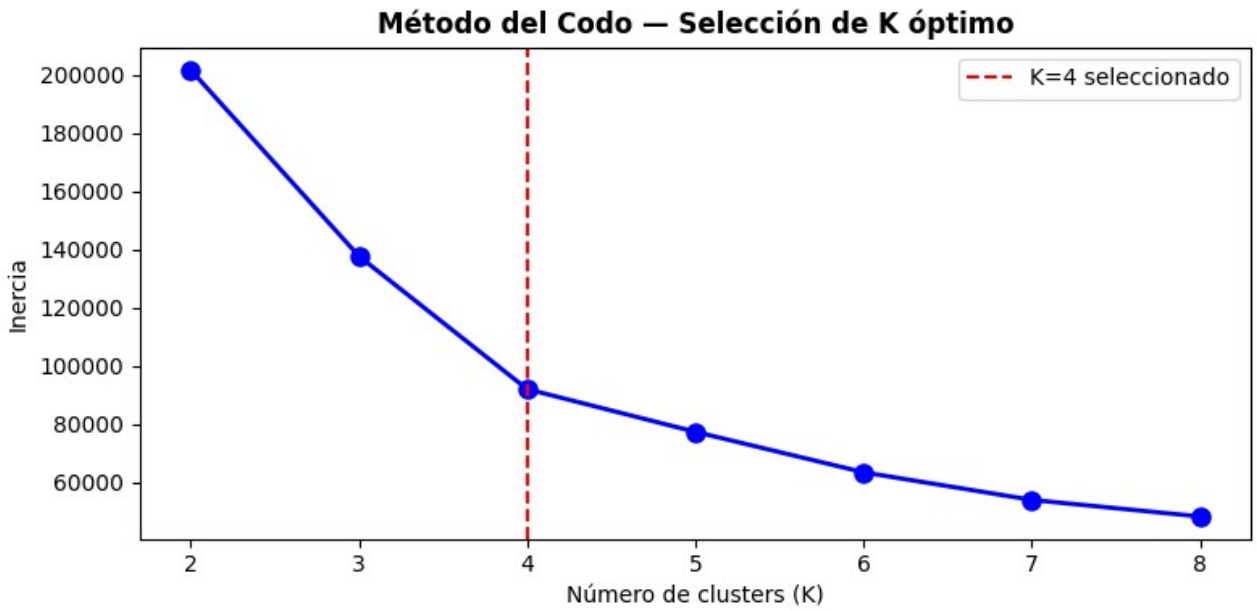

Figura 12: Selección de la k óptima

Dada la gráfica de codo, se observa una reducción significativa de la inercia (La inercia en K-means es una medida de qué tan bien están agrupados los datos dentro de cada cluster. En términos simples, representa qué tan cerca están los puntos de su centroide) a medida que se incrementa el número de clusters, especialmente entre 2 y 4 grupos. Este comportamiento indica que, en ese rango, cada nuevo cluster aporta una mejora importante en la agrupación de los datos. A partir de K=4, la curva comienza a aplanarse, lo que sugiere que agregar más clusters genera mejoras cada vez menores. Es decir, aunque la inercia sigue disminuyendo, el aporte adicional ya no es tan relevante y podría implicar una segmentación innecesariamente compleja.

En este sentido, la elección de 4 clusters se considera adecuada, ya que permite obtener grupos bien diferenciados sin sobrecomplicar el modelo, facilitando además su interpretación y aplicación en estrategias de negocio.

K-means

Segmento	Clientes	%	Recency (días)	Frecuencia	Ticket Promedio
En Riesgo de Abandono	37,526	40.2 %	387	1.00	$133.46
Clientes Fieles	2,772	3.0 %	220	2.11	$289.68
VIP / Alto Valor	2,418	2.6 %	239	1.01	$1,160.91
Nuevos / Recientes	50,642	54.2 %	128	1.00	$134.36

Segmento	Ganancia Total (BRL)
En Riesgo de Abandono	$5,008,136
Clientes Fieles	$802,994
VIP / Alto Valor	$2,807,072
Nuevos / Recientes	$6,804,261

Cuadro 12: Segmentación de clientes basada en RFM

En general, se observa que la mayor parte de los clientes se concentra en los segmentos de **Nuevos/Recientes** (54.2 %) y **En riesgo de abandono** (40.2 %), ambos caracterizados por una baja frecuencia de compra, lo que indica un comportamiento predominantemente ocasional. Sin embargo, mientras los primeros han comprado recientemente, el segundo grupo presenta altos niveles de inactividad, representando una oportunidad clave para estrategias de reactivación.

Por otra parte, los segmentos de **Clientes fieles** y **VIP/Alto valor**, aunque representan una proporción reducida de la base, concentran un alto valor estratégico. Los clientes fieles destacan por su mayor frecuencia de compra, mientras que los VIP generan un alto ingreso por transacción, evidenciando su relevancia en términos de rentabilidad.

En conjunto, los resultados muestran una base amplia pero poco recurrente, con oportunidades claras tanto en retención de clientes recientes como en reactivación de clientes inactivos y fortalecimiento de los segmentos de mayor valor.

Gráficamente

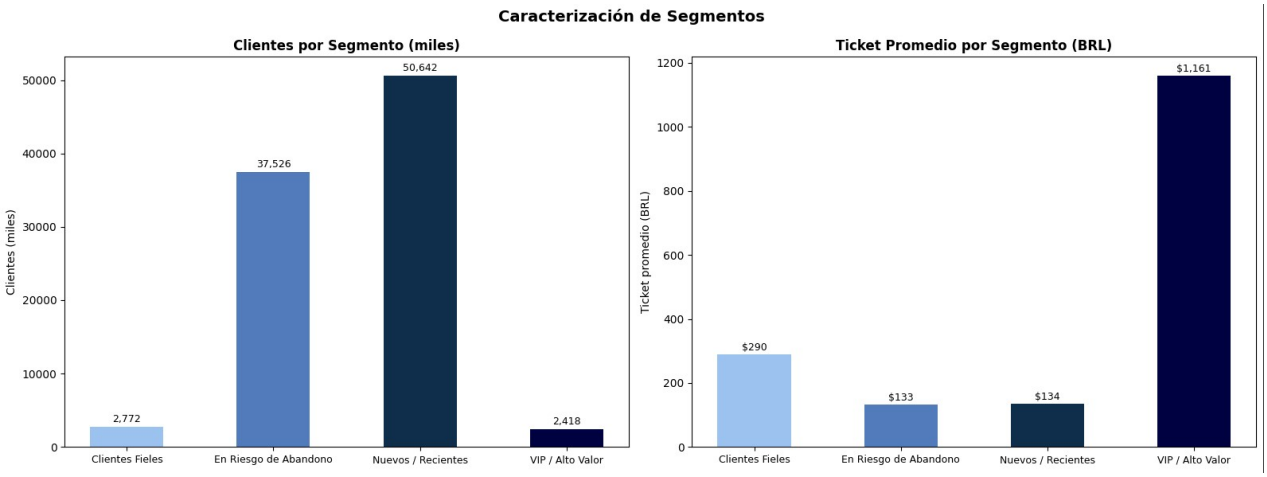

Figura 13: Punto 3

En general, se observa un contraste claro entre el volumen de clientes y el valor que aportan. La mayoría de la base se concentra en los segmentos de **Nuevos/Recientes** y **En riesgo de abandono**, pero ambos presentan un ticket promedio bajo y muy similar, lo que indica que, aunque son muchos, su aporte individual es limitado.

Por otro lado, el segmento **VIP/Alto valor**, aunque es pequeño, tiene un gasto promedio considerablemente mayor, lo que lo convierte en un grupo clave para la rentabilidad del negocio. Asimismo, los **Clientes fieles** destacan por su mayor frecuencia, pero siguen siendo una proporción reducida dentro de la base total.

Adicionalmente, el alto número de clientes en riesgo, junto con la baja cantidad de clientes recurrentes, sugiere que el comportamiento general es poco frecuente, es decir, muchos clientes compran una vez y no regresan. En conjunto, los resultados indican que el principal reto no está en atraer nuevos clientes, sino en lograr que estos vuelvan a comprar, fortaleciendo la retención y el valor a largo plazo.

6. Punto 4 — Arquitectura del modelo de recomendación en tiempo real

6.1. Descripción del sistema

Se propone una arquitectura de recomendación híbrida que combina tres enfoques complementarios:

- **Filtrado colaborativo:** recomienda productos basándose en el comportamiento de usuarios con perfiles similares (çlientes como tú también compraron. . . ”).

- **Content-based filtering:** sugiere ítems similares a los que el cliente ya ha comprado, basándose en atributos de producto (categoría, precio, tags).
- **Segmentación RFM:** integra el perfil del cliente (Nuevos, Fieles, VIP, En riesgo) para personalizar las recomendaciones según su valor y comportamiento histórico.

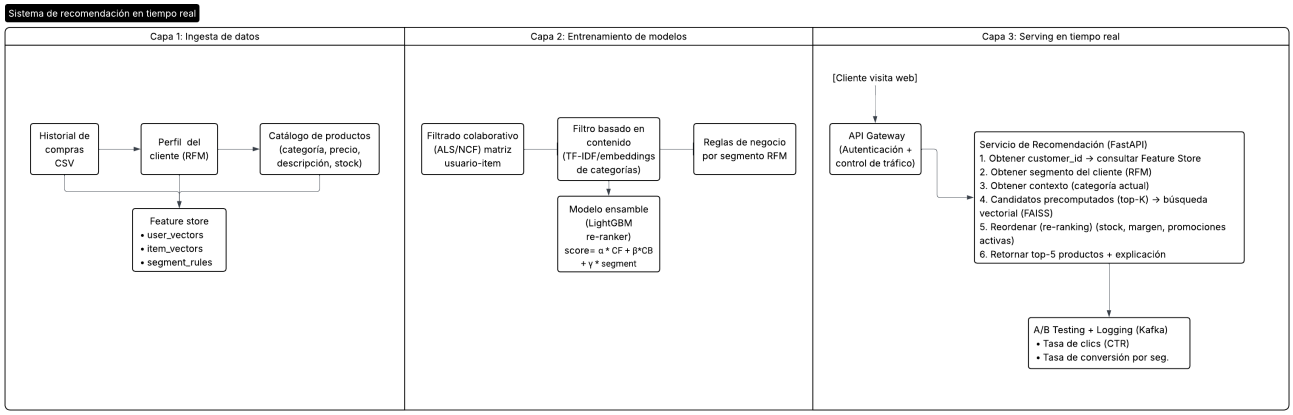

Figura 14: Diagrama

Componente	Tecnologías Propuestas
Batch processing	Apache Spark / dbt
Feature store	Redis (low-latency) + S3 (cold storage)
Modelo CF	Alternating Least Squares (implicit)
ANN search	FAISS o Pinecone
Re-ranker	LightGBM / XGBoost
Serving	FastAPI + Kubernetes
Monitoreo	MLflow + Grafana

Cuadro 13: Arquitectura tecnológica propuesta

El sistema de recomendación funciona detectando cuando un cliente entra a la página web y, en tiempo real, utiliza su perfil (basado en comportamiento de compra) y su historial para identificar productos que podrían interesarle. Primero, consulta una base de datos optimizada donde ya están almacenadas las características del usuario y de los productos; luego, genera un conjunto de posibles recomendaciones usando modelos que aprenden de patrones de consumo (por ejemplo, productos que compran personas similares o artículos relacionados con lo que ha visto). Finalmente, estos productos se ordenan según la probabilidad de compra y criterios del negocio (como disponibilidad o promociones), y se muestran al usuario en cuestión de milisegundos, mientras el sistema registra su comportamiento para seguir mejorando.

7. Punto 5 — Mejor ubicación para centro comercial insignia

Para el desarrollo del punto, se analiza la distribución geográfica de ventas (órdenes entregadas) a nivel de estado, ciudad y código postal, mediante el cruce de las tablas orders, customers y payments, con el fin de obtener el ingreso total por ubicación. A partir de este análisis, se identifican las zonas con mayor volumen y ganancias.

Adicionalmente, se integran datos de geolocalización para obtener las coordenadas exactas de las áreas con mayor concentración. Como supuesto, se define la "ciudad con mayores ventas" como aquella con mayor ganancia total acumulada y, dentro de esta, el mejor punto se determina a partir del código postal con mayor concentración de clientes compradores.

Métrica	**Valor**
Top 10 ventas	
SP (Órdenes / Clientes)	40501 / 39156
Ganancia SP	$5,770,266.19
RJ (Órdenes / Clientes)	12350 / 11917
Ganancia RJ	$2,055,690.45
MG (Órdenes / Clientes)	11354 / 11001
Ganancia MG	$1,819,277.61
RS (Órdenes / Clientes)	5345 / 5168
Ganancia RS	$861,802.40
PR (Órdenes / Clientes)	4923 / 4769
Ganancia PR	$781,919.55

Métrica	**Valor**
Top 10 ciudades	
Sao Paulo (Órdenes)	15045
Ganancia Sao Paulo	$2,108,162.22
Rio de Janeiro (Órdenes)	6601
Ganancia Rio de Janeiro	$1,111,872.32
Belo Horizonte (Órdenes)	2697
Ganancia Belo Horizonte	$406,050.87
Brasilia (Órdenes)	2071
Ganancia Brasilia	$345,221.87
Curitiba (Órdenes)	1489
Ganancia Curitiba	$238,582.26

Cuadro 14: Top estados por ganancia y ventas

En general, se observa una alta concentración de la ganancia en ciertos estados y ciudades. En particular, el estado de **SP (São Paulo)** lidera ampliamente tanto en número de órdenes como en ingresos y cantidad de clientes, posicionándose como el principal mercado del negocio. Le siguen estados como RJ y MG, aunque con una participación considerablemente menor.

A nivel de ciudades, São Paulo se consolida como la principal fuente de ingresos, superando ampliamente al resto, seguida por Río de Janeiro y Belo Horizonte. Esta concentración geográfica indica que gran parte del desempeño del negocio depende de unos pocos centros urbanos.

En conjunto, los resultados evidencian una fuerte centralización de la demanda, lo que sugiere oportunidades tanto para fortalecer la presencia en estas zonas clave como para explorar el crecimiento en regiones con menor participación.

Métrica	Valor
Top 10 códigos postales en São Paulo por ganancia	
CP 4144 (Órdenes / Clientes)	22 / 20
Ganancia CP 4144	$8,513.37
CP 2435 (Órdenes / Clientes)	28 / 27
Ganancia CP 2435	$8,381.47
CP 5017 (Órdenes / Clientes)	29 / 29
Ganancia CP 5017	$6,087.36
CP 4302 (Órdenes / Clientes)	27 / 26
Ganancia CP 4302	$5,896.55
CP 1311 (Órdenes / Clientes)	27 / 26
Ganancia CP 1311	$5,690.85
CP 2402 (Órdenes / Clientes)	18 / 18
Ganancia CP 2402	$5,653.84
CP 8240 (Órdenes / Clientes)	20 / 19
Ganancia CP 8240	$5,433.15
CP 4543 (Órdenes / Clientes)	19 / 17
Ganancia CP 4543	$5,110.22
CP 4559 (Órdenes / Clientes)	9 / 9
Ganancia CP 4559	$5,095.56
CP 2995 (Órdenes / Clientes)	7 / 7
Ganancia CP 2995	$5,055.82
Mejor ubicación	
Ciudad	São Paulo
Código postal	4144
Latitud	-23.619120
Longitud	-46.638893
Órdenes	22
Ganancia	$8,513.37

Cuadro 15: Top códigos postales en São Paulo y mejor ubicación identificada

En general, se observa que, incluso dentro de la ciudad de São Paulo, la ganancia se concentra en ciertos códigos postales específicos. El prefijo **4144** se posiciona como la zona de mayor desempeño, alcanzando el mayor nivel de ingresos con un número relativamente bajo de órdenes, lo que sugiere un mayor valor por transacción.

Gráficamente

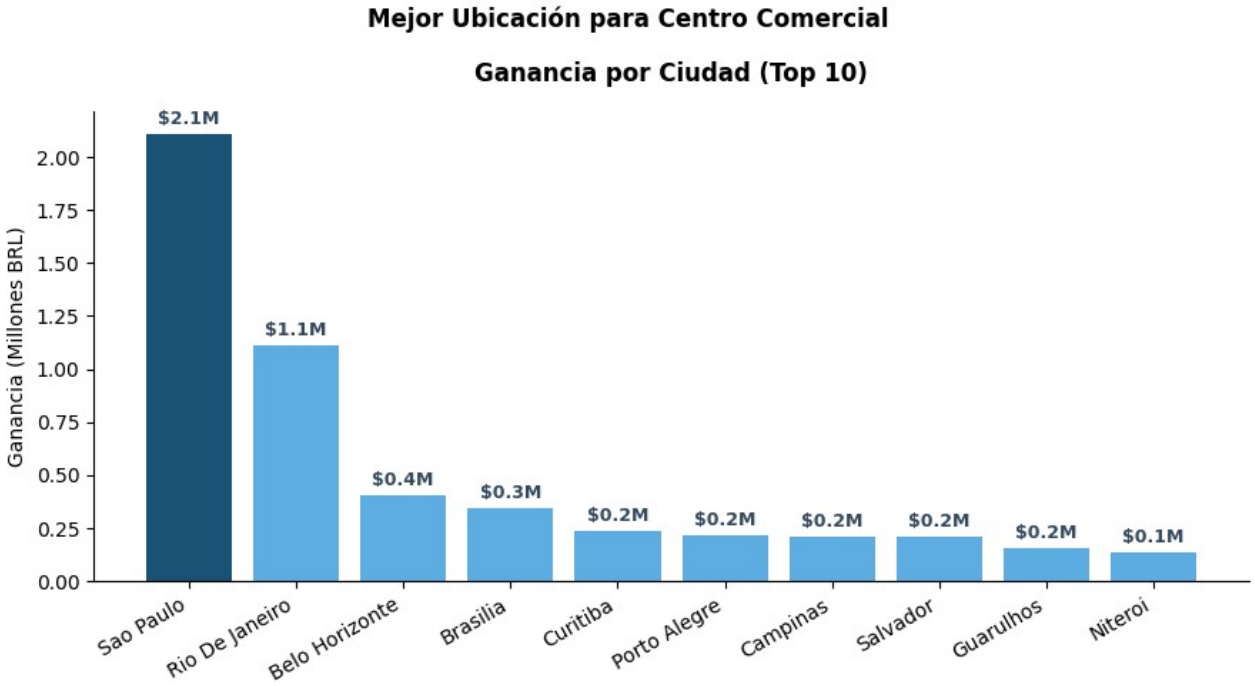

Figura 15: Punto 5

En general, se observa que la ciudad de **São Paulo** concentra el mayor nivel de ventas, lo que la posiciona como el mercado más relevante para la apertura de un centro comercial físico. A nivel más desagregado, la ganancia se concentra en ciertos códigos postales, destacándose el código postal 4144 como la zona de mejor desempeño dentro de la ciudad. En conjunto, los datos sugieren que la ubicación óptima para un centro comercial insignia se encuentra en São Paulo, particularmente en áreas cercanas al código postal 4144, donde se concentra una mayor generación de ingresos.

8. Punto 6 — Base de conocimientos (JSON)

Se construye una base de conocimientos estructurada en formato JSON para los tres productos de mayor volumen de ventas. Los precios reales se extraen directamente del dataset (join entre order_items, products y translations). Las descripciones son redactadas de forma atractiva y orientada al cliente final.
Se define un formato JSON:

Formato JSON

```
knowledge_base = {
    "metadata": {
        "version": "1.0",
        "created_date": "2026-03-27",
        "source_dataset": "E-Commerce Brasil",
        "description": "Base de conocimientos de productos top para el Agente IA"
    },
    "products": [
        {
            "id": "CAT-001",
            "category": "bed_bath_table",
            "category_es": "Cama, Baño y Mesa",
            "rank_volume": 1,
            "description": ("Transforma tu espacio en un hogar acogedor y elegante con n
                            "baño y mesa. Desde sábanas que van a crear un espacio perfe
                            "decorativos que elevan cualquier ambiente, esta categoría c
            ),
            "avg_price_brl": price_stats['bed_bath_table']['avg_price'],
            "median_price_brl": price_stats['bed_bath_table']['median_price'],
            "price_range_brl": {
                "min": price_stats['bed_bath_table']['min_price'],
                "max": price_stats['bed_bath_table']['max_price']
            },
            "total_units_sold": price_stats['bed_bath_table']['total_units'],
            "tags": ["hogar", "alta-rotación", "regalo", "accesible"],
            "ideal_for_segments": ["Nuevos", "Dormidos", "Clientes Fieles"]
        },
```

9. Punto 7 — System prompts para agente de IA hiper-personalizado

Para el desarrollo del punto se diseñan 3 System Prompts que adaptan el tono, el lenguaje y el tipo de recomendación del LLM según el perfil del cliente. Cada prompt ingiere dinámicamente las variables requeridas: ‘Edad‘, ‘Género‘, ‘perfil_de_cliente‘, ‘historial_compras‘, ‘base_conocimiento‘.

Variable calculada: ‘historial_compras‘ se define como: categorías compradas, ticket promedio, última compra hace N días, número de órdenes totales.
Se define un formato JSON:

Formato JSON

```
{
  "categorias_compradas": ["health_beauty", "sports_leisure"],
  "ticket_promedio": 145.50,
  "ultima_compra_hace_dias": 30,
  "total_ordenes": 3,
  "experiencia_previa": "positiva | negativa | neutral"
}
```

Esta variable resume el comportamiento histórico del cliente y es calculada a partir del dataset antes de ser inyectada al prompt.

10. Conclusiones finales

- **Sobre el negocio:** la demanda está fuertemente concentrada geográficamente (São Paulo representa la gran mayoría del volumen e ingresos).
- **Sobre la experiencia del cliente:** el principal factor de insatisfacción es logístico. Un pequeño porcentaje de entregas tardías (8.1 %) genera un impacto desproporcionado en la percepción del servicio. Mejorar el cumplimiento de los tiempos estimados de entrega tendría el mayor retorno en satisfacción.
- **Sobre los clientes:** la base es amplia pero con baja recurrencia. La mayoría compra una sola vez. El reto central es la retención y reactivación, no la adquisición. El segmento VIP, aunque pequeño, concentra un valor desproporcionado y merece atención diferenciada.
- **Sobre la IA:** los system prompts diseñados permiten que un mismo LLM genere experiencias radicalmente distintas para perfiles de cliente contrastantes, lo que demuestra el potencial de la hiper-personalización sin necesidad de modelos separados.

11. Limitaciones y Oportunidades de Mejora

- El dataset no contiene variables demográficas (edad, género), lo que limita la segmentación a variables comportamentales. La integración con el CRM es clave para enriquecer los perfiles.
- El modelo de recomendación es una propuesta arquitectónica; su implementación requeriría datos de navegación en tiempo real (sesiones web, clics, tiempo en página) que no están disponibles en el dataset actual.

12. Anexos

El código en Python desarrollado para realizar la prueba se adjunta como un archivo independiente, junto con las diapositivas utilizadas en la presentación del proyecto. Además, se incluye el enlace de git con el código.

13. Referencias

- RFM Analysis - GitHub [Recurso en línea]. Disponible en: https://www.kaggle.com/code/azizesultanbilge/rfm-analysis
- Customer Segmentation (RFM and KMeans) - GitHub [Recurso en línea]. Disponible en: https://www.kaggle.com/code/abdocan/customer-segmentation-rfm-and-kmeans
- End to End Customer Service System with prompt - GitHub [Recurso en línea]. Disponible en: https://www.kaggle.com/code/youssef19/end-to-end-customer-service-system-with-prom
- CloudMart — Multicloud DevOps AI Retail Platform - GitHub [Recurso en línea]. Disponible en: https://github.com/tarakgit/cloudmart
- Drug Recommendation System (FAANG-Level MLOps Project) - GitHub [Recurso en línea]. Disponible en: https://github.com/rtx4070-m4/drug-recommendation-system-mlops